

# Tugas 9: Tugas Praktikum Mandiri 09

Revani – 0110224111 <sup>1</sup>

<sup>1</sup> Teknik Informatika, STT Terpadu Nurul Fikri, Depok

\*E-mail: [0110224111@student.nurulfikri.ac.id](mailto:0110224111@student.nurulfikri.ac.id)

**Abstract.** Pada tugas praktikum mandiri 9 ini, dilakukan penerapan metode klasifikasi Naive Bayes untuk memprediksi jenis diagnosis kanker payudara berdasarkan berbagai parameter pengukuran jaringan seperti radius, tekstur, perimeter, dan area. Tujuan dari latihan ini adalah memahami bagaimana Naive Bayes bekerja dalam mengolah data numerik, bagaimana proses preprocessing mempengaruhi performa model, dan bagaimana hasil prediksi dapat dianalisis menggunakan confusion matrix serta classification report. Dataset yang digunakan adalah data kanker payudara, yang berisi label diagnosis “M” untuk malignant (ganas) dan “B” untuk benign (jinak). Setelah melalui tahap pembersihan data, encoding label, pembagian data, standardisasi, pelatihan model, hingga evaluasi, model Naive Bayes berhasil memberikan performa klasifikasi yang cukup baik. Praktikum ini juga memberikan gambaran nyata bagaimana machine learning dapat membantu proses deteksi dini penyakit dengan memanfaatkan pola dari data medis.

## 1. Penjelasan Hasil Praktikum Mandiri

Pada praktikum ini, Hasil dari proses klasifikasi menunjukkan bahwa algoritma Naive Bayes mampu melakukan prediksi diagnosis kanker payudara dengan tingkat akurasi tinggi. Setelah data dibersihkan dari kolom yang tidak relevan dan dilakukan encoding pada kolom diagnosis, model dilatih pada data training yang telah distandarisasi. Hasil evaluasi menggunakan confusion matrix dan classification report menunjukkan bahwa model dapat membedakan antara kanker jinak dan ganas dengan cukup baik. Secara keseluruhan, implementasi ini membuktikan bahwa Naive Bayes menjadi salah satu algoritma yang cocok untuk dataset dengan banyak fitur numerik seperti dataset kanker. Berikut ini adalah hasil praktikum yang saya kerjakan pada praktikum mandiri 09.

## 2. Penjelasan Kode Program

```
from google.colab import drive
drive.mount('/content/drive')
path = "/content/drive/MyDrive/Colab Notebooks/Machine Learning/Praktikum09"
```

Langkah awal yang dilakukan adalah menghubungkan Google Colab dengan Google Drive agar notebook bisa membaca file CSV yang disimpan dalam folder Drive. Variabel path digunakan sebagai alamat folder tempat dataset kanker disimpan. Output yang dihasilkan yaitu

colab akan meminta izin akses Drive. Jika berhasil, akan muncul pesan bahwa Drive berhasil di-mount seperti yang ditunjukkan pada Gambar 1.

```
Latihan 09 - Naive Bayes

▼ Menghubungkan Drive

[31] ✓ 4s from google.colab import drive
      drive.mount('/content/drive')

▼ Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/content/drive", force_remount=True).

[32] ✓ 0s path = "/content/drive/MyDrive/Colab Notebooks/Machine Learning/Praktikum09"
```

**Gambar 1.** Pada bagian ini ditunjukkan menghubungkan *gdrive*

```
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import confusion_matrix
from sklearn.metrics import classification_report
```

Bagian ini memuat semua library yang diperlukan, seperti pandas untuk membaca data, numpy untuk operasi numerik, seaborn/matplotlib untuk visualisasi, dan library scikit-learn untuk pemodelan Naive Bayes seperti yang ditunjukkan pada Gambar 2.

```
▼ Import Library

[33] ✓ 0s import pandas as pd
      import numpy as np
      import matplotlib.pyplot as plt
      import seaborn as sns
      from sklearn.model_selection import train_test_split
      from sklearn.metrics import accuracy_score
      from sklearn.preprocessing import StandardScaler
      from sklearn.metrics import confusion_matrix
      from sklearn.metrics import classification_report
```

**Gambar 2.** Pada bagian ini ditunjukkan untuk mengimpor library.

```
cancer_data = pd.read_csv(path + '/Data/cancer.csv')
```

Bagian ini untuk membaca dataset kanker.

```
cancer_data.head()
```

```
cancer_data.tail()
```

Bagian ini untuk menampilkan 5 baris pertama dan 5 baris terakhir.

```
cancer_data.info()
```



```
[37]
✓ Os
cancer_data.info()

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 569 entries, 0 to 568
Data columns (total 33 columns):
#   Column                                     Non-Null Count  Dtype
---  ---
0    id                                         569 non-null    int64
1    diagnosis                                 569 non-null    object
2    radius_mean                             569 non-null    float64
3    texture_mean                             569 non-null    float64
4    perimeter_mean                           569 non-null    float64
5    area_mean                               569 non-null    float64
6    smoothness_mean                           569 non-null    float64
7    compactness_mean                           569 non-null    float64
8    concavity_mean                             569 non-null    float64
9    concave points_mean                       569 non-null    float64
10   symmetry_mean                             569 non-null    float64
11   fractal_dimension_mean                     569 non-null    float64
12   radius_se                                  569 non-null    float64
13   texture_se                                 569 non-null    float64
14   perimeter_se                               569 non-null    float64
15   area_se                                   569 non-null    float64
16   smoothness_se                             569 non-null    float64
17   compactness_se                             569 non-null    float64
18   concavity_se                               569 non-null    float64
19   concave points_se                         569 non-null    float64
20   symmetry_se                               569 non-null    float64
21   fractal_dimension_se                       569 non-null    float64
22   radius_worst                              569 non-null    float64
23   texture_worst                             569 non-null    float64
24   perimeter_worst                           569 non-null    float64
25   area_worst                                569 non-null    float64
26   smoothness_worst                          569 non-null    float64
27   compactness_worst                         569 non-null    float64
28   concavity_worst                           569 non-null    float64
29   concave points_worst                      569 non-null    float64
30   symmetry_worst                             569 non-null    float64
31   fractal_dimension_worst                   569 non-null    float64
32   Unnamed: 32                               0 non-null      float64
dtypes: float64(31), int64(1), object(1)
memory usage: 146.8+ KB
```

Gambar 4. Pada bagian ini ditunjukkan untuk informasi dataset.

```
[38]
✓ Os
cancer_data.describe()

count    5.690000e+02    569.000000    569.000000    569.000000    569.000000    569.000000    569.000000    569.000000    569.000000    569.000000    ...    569.000000    569.000000    569.000000    569.000000    569.000000
mean     3.037183e+07    14.127292    19.289649    91.969033    654.809104    0.096360    0.104341    0.088799    0.048919    0.181162    ...    25.677223    107.261213    880.583128    0.132369    0.254265
std      1.250206e+08    3.524049    4.301036    24.298981    351.914129    0.014064    0.052813    0.079720    0.038803    0.027414    ...    6.146258    33.602542    569.356993    0.022832    0.157336
min      8.670000e+03    6.981000    9.710000    43.790000    143.500000    0.052630    0.019380    0.000000    0.000000    0.106000    ...    12.020000    50.410000    185.200000    0.071170    0.027290
25%     8.692180e+05    11.700000    16.170000    75.170000    420.300000    0.086370    0.064920    0.029560    0.020310    0.161900    ...    21.080000    84.110000    515.300000    0.116600    0.147200
50%     9.068240e+05    13.370000    18.840000    86.240000    551.100000    0.095870    0.092630    0.061540    0.033500    0.179200    ...    25.410000    97.660000    686.500000    0.131300    0.219900
75%     8.813129e+06    15.780000    21.800000    104.100000    782.700000    0.105300    0.130400    0.130700    0.074000    0.195700    ...    29.720000    125.400000    1084.000000    0.146000    0.339100
max      9.113205e+08    28.110000    39.280000    188.500000    2501.000000    0.163400    0.345400    0.426800    0.201200    0.304000    ...    49.540000    251.200000    4254.000000    0.222600    1.058000

8 rows x 32 columns

[39]
✓ Os
cancer_data.shape

(569, 33)
```

Gambar 5. Pada bagian ini ditunjukkan untuk statistic deskriptif dan menunjukan baris kolom.

```
cancer_data.isnull().sum()
```

Fungsi ini menghitung berapa banyak nilai kosong pada masing-masing kolom. Output yang dihasilkan yaitu semua kolom memiliki nol missing value, kecuali Unnamed: 32 yang memiliki 569 missing value (kolom kosong) seperti yang ditunjukkan pada Gambar 6.

Missing Value

[48] ✓ 0s `cancer_data.isnull().sum()`

|                        |   |
|------------------------|---|
| ...                    | 0 |
| id                     | 0 |
| diagnosis              | 0 |
| radius_mean            | 0 |
| texture_mean           | 0 |
| perimeter_mean         | 0 |
| area_mean              | 0 |
| smoothness_mean        | 0 |
| compactness_mean       | 0 |
| concavity_mean         | 0 |
| concave points_mean    | 0 |
| symmetry_mean          | 0 |
| fractal_dimension_mean | 0 |
| radius_se              | 0 |
| texture_se             | 0 |
| perimeter_se           | 0 |
| area_se                | 0 |
| smoothness_se          | 0 |
| compactness_se         | 0 |
| concavity_se           | 0 |
| concave points_se      | 0 |

**Gambar 6.** Pada bagian ini ditunjukkan untuk missing value.

```
cancer_data = cancer_data.drop(columns=['id', 'Unnamed: 32'], axis=1)
```

Kolom id dan Unnamed: 32 tidak berhubungan dengan diagnosis, sehingga dihapus agar tidak mengganggu model. Outputnya yaitu dataset akan berkurang menjadi 31 kolom seperti yang ditunjukkan pada Gambar 7.

```
cancer_data = cancer_data.drop(columns=['id', 'Unnamed: 32'], axis=1)
```

**Gambar 7.** Pada bagian ini ditunjukkan untuk menghapus kolom tidak relevan.

```
from sklearn.preprocessing import LabelEncoder
le = LabelEncoder()
cancer_data['diagnosis_encoded'] = le.fit_transform(cancer_data['diagnosis'])
```

Diagnosis berupa huruf B/M harus diubah menjadi angka apabila B berarti 0 dan M berarti 1, jadi kolom baru bernama diagnosis\_encoded ditambahkan ke dataset. Output yang dihasilkan yaitu kolom baru berisi angka 0 dan 1 seperti yang ditunjukkan pada Gambar 8.

```
# encode kolom diagnosis
from sklearn.preprocessing import LabelEncoder
le = LabelEncoder()
cancer_data['diagnosis_encoded'] = le.fit_transform(cancer_data['diagnosis'])
```

**Gambar 8.** Pada bagian ini ditunjukkan encoding diagnosis.

```
X = cancer_data.drop(columns=['diagnosis', 'diagnosis_encoded'])
y = cancer_data['diagnosis_encoded']

print("\nData setelah Preprocessing\n")
print(cancer_data.head())
```

X berisi seluruh fitur kecuali diagnosis dan y hanya berisi diagnosis encoded sebagai target klasifikasi. Output yang dihasilkan yaitu dataset fitur dan target dipisahkan dengan benar seperti yang ditunjukkan pada Gambar 9.

```
# menentukan fitur dan target
X = cancer_data.drop(columns=['diagnosis', 'diagnosis_encoded'])
y = cancer_data['diagnosis_encoded']

print("\nData setelah Preprocessing\n")
print(cancer_data.head())
```

Data setelah Preprocessing

|   | diagnosis | radius_mean | texture_mean | perimeter_mean | area_mean | \ |
|---|-----------|-------------|--------------|----------------|-----------|---|
| 0 | M         | 17.99       | 10.38        | 122.80         | 1001.0    |   |
| 1 | M         | 20.57       | 17.77        | 132.90         | 1326.0    |   |
| 2 | M         | 19.69       | 21.25        | 130.00         | 1203.0    |   |
| 3 | M         | 11.42       | 20.38        | 77.58          | 386.1     |   |
| 4 | M         | 20.29       | 14.34        | 135.10         | 1297.0    |   |

|   | smoothness_mean | compactness_mean | concavity_mean | concave points_mean | \ |
|---|-----------------|------------------|----------------|---------------------|---|
| 0 | 0.11840         | 0.27760          | 0.3001         | 0.14710             |   |
| 1 | 0.08474         | 0.07864          | 0.0869         | 0.07017             |   |
| 2 | 0.10960         | 0.15990          | 0.1974         | 0.12790             |   |
| 3 | 0.14250         | 0.28390          | 0.2414         | 0.10520             |   |
| 4 | 0.10030         | 0.13280          | 0.1980         | 0.10430             |   |

|   | symmetry_mean | ... | texture_worst | perimeter_worst | area_worst | \ |
|---|---------------|-----|---------------|-----------------|------------|---|
| 0 | 0.2419        | ... | 17.33         | 184.60          | 2019.0     |   |
| 1 | 0.1812        | ... | 23.41         | 158.80          | 1956.0     |   |
| 2 | 0.2069        | ... | 25.53         | 152.50          | 1709.0     |   |
| 3 | 0.2597        | ... | 26.50         | 98.87           | 567.7      |   |
| 4 | 0.1809        | ... | 16.67         | 152.20          | 1575.0     |   |

|   | smoothness_worst | compactness_worst | concavity_worst | concave points_worst | \ |
|---|------------------|-------------------|-----------------|----------------------|---|
| 0 | 0.1622           | 0.6656            | 0.7119          | 0.2654               |   |
| 1 | 0.1238           | 0.1866            | 0.2416          | 0.1860               |   |
| 2 | 0.1444           | 0.4245            | 0.4504          | 0.2430               |   |
| 3 | 0.2098           | 0.8663            | 0.6869          | 0.2575               |   |
| 4 | 0.1374           | 0.2050            | 0.4000          | 0.1625               |   |

|   | symmetry_worst | fractal_dimension_worst | diagnosis_encoded |
|---|----------------|-------------------------|-------------------|
| 0 | 0.4601         | 0.11890                 | 1                 |
| 1 | 0.2750         | 0.08902                 | 1                 |
| 2 | 0.3613         | 0.08758                 | 1                 |
| 3 | 0.6638         | 0.17300                 | 1                 |
| 4 | 0.2364         | 0.07678                 | 1                 |

[5 rows x 32 columns]

**Gambar 9.** Pada bagian ini menentukan fitur dan target.

```

features_to_plot = ['radius_mean', 'texture_mean', 'perimeter_mean']
fig, axes = plt.subplots(1, len(features_to_plot), figsize=(18, 6))

for i, feature in enumerate(features_to_plot):
    sns.boxplot(x='diagnosis', y=feature, data = cancer_data, palette='Set2', ax=axes[i])
    axes[i].set_xlabel('Diagnosis')
    axes[i].set_ylabel(feature)

plt.tight_layout()
plt.show()

```

Membuat boxplot untuk melihat apakah pasien kanker jinak dan ganas memiliki distribusi fitur yang berbeda. Outputnya yaitu akan tampil tiga boxplot yang menunjukkan bahwa fitur kanker ganas cenderung memiliki nilai lebih tinggi seperti yang ditunjukkan pada Gambar 10.



**Gambar 10.** Pada bagian ini ditunjukkan visualisasi outlier / boxplot.

```

#Pemisahan Data (80% training, 20% testing)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

#scaling fitur
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

print(f"\nUkuran Data Training: {X_train.shape}")
print(f"Ukuran Data Testing: {X_test.shape}")

```

Dataset dipisahkan menjadi 80% data training dan 20% data testing. Output yang dihasilkan yaitu data training 455 dan data testing 114. Kode StandardScaler menstandarkan data agar semua fitur memiliki skala yang sama (mean=0, std=1). Hal ini penting untuk Naive Bayes. Jadi output `X_train` dan `X_test` berubah menjadi array yang sudah terstandarisasi seperti yang ditunjukkan pada Gambar 11.

```
#Pemisahan Data (80% training, 20% testing)
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

#scaling fitur
scaler = StandardScaler()
X_train = scaler.fit_transform(X_train)
X_test = scaler.transform(X_test)

print(f"\nUkuran Data Training: {X_train.shape}")
print(f"Ukuran Data Testing: {X_test.shape}")

'''
Ukuran Data Training: (455, 30)
Ukuran Data Testing: (114, 30)'''
```

**Gambar 11.** Pada bagian ini membagi data train test dan scaling data.

```
#inisialisasi model
from sklearn.naive_bayes import GaussianNB

model = GaussianNB()
model.fit(X_train, y_train)

#prediksi pada data uji
test_pred_nb = model.predict(X_test)

print("\nAkurasi Naive Bayes berhasil dilatih dan membuat prediksi.")
```

Membuat model GaussianNB karena semua fitur numerik dan melatihnya menggunakan data training. Serta Model memprediksi diagnosis pasien pada data testing dengan output yang dihasilkan yaitu Variabel `test_pred_nb` berisi daftar prediksi: 0 dan 1 seperti yang ditunjukkan pada Gambar 12.



## Pelatihan Model Naive Bayes

```
#inisialisasi model
from sklearn.naive_bayes import GaussianNB

model = GaussianNB()
model.fit(X_train, y_train)

#prediksi pada data uji
test_pred_nb = model.predict(X_test)

print("\nAkurasi Naive Bayes berhasil dilatih dan membuat prediksi.")

...
Akurasi Naive Bayes berhasil dilatih dan membuat prediksi.
```

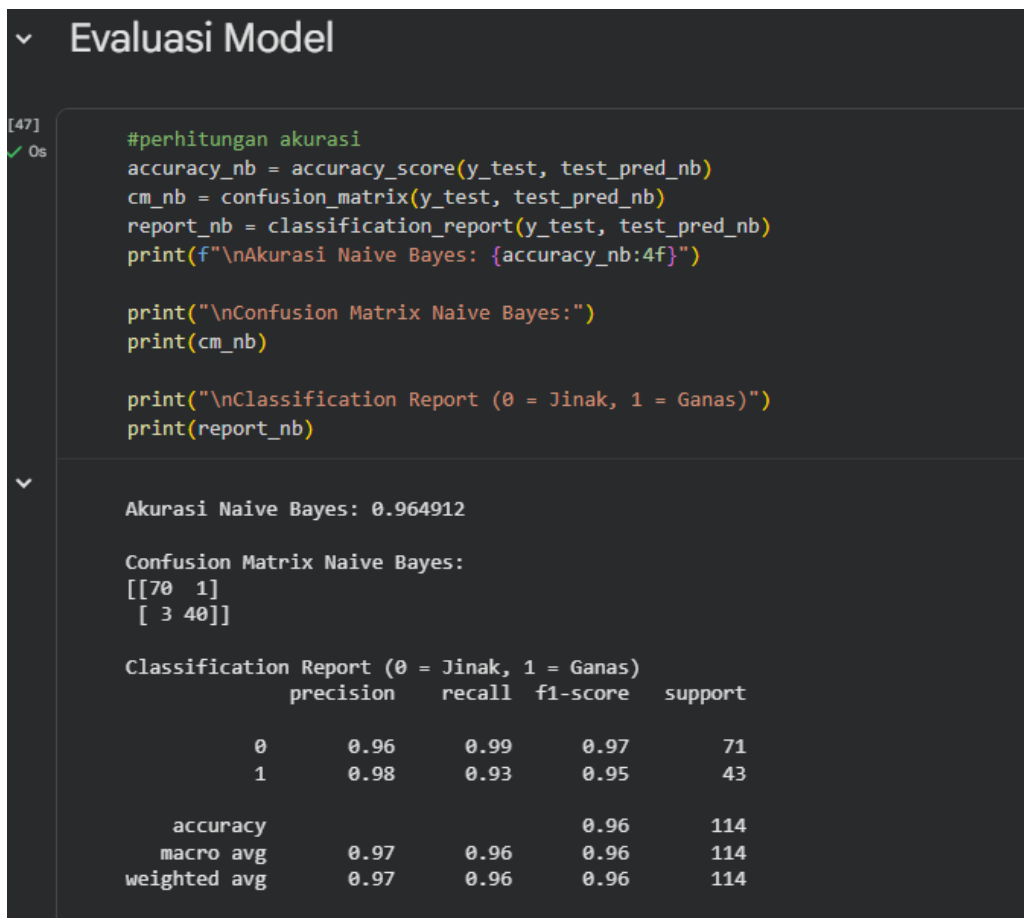
**Gambar 12.** Pada bagian ini ditunjukkan pelatihan model dan prediksi data uji.

```
#perhitungan akurasi
accuracy_nb = accuracy_score(y_test, test_pred_nb)
cm_nb = confusion_matrix(y_test, test_pred_nb)
report_nb = classification_report(y_test, test_pred_nb)
print(f"\nAkurasi Naive Bayes: {accuracy_nb:4f}")

print("\nConfusion Matrix Naive Bayes:")
print(cm_nb)

print("\nClassification Report (0 = Jinak, 1 = Ganas)")
print(report_nb)
```

Kode ini untuk menghitung akurasi model, membuat confusion matrix dan menampilkan precision, recall, f1-score. Output yang ditampilkan yaitu angka akurasi, matriks perbandingan prediksi benar atau salah, serta laporan klasifikasi. Biasanya akurasi mencapai 90%+ seperti yang ditunjukkan pada Gambar 13.



**Gambar 13.** Pada bagian ini ditunjukkan evaluasi model.

```
class_name = ['Bening (0)', 'Malignant (1)']

plt.figure(figsize=(8, 6))
sns.heatmap(cm_nb, annot=True, fmt='d', cmap='RdPu', xticklabels=class_name, yticklabels=class_name)
plt.xlabel('Predicted')
plt.ylabel('True')
plt.title('Confusion Matrix - Naive Bayes')
```

Kode ini untuk menampilkan confusion matrix dalam bentuk heatmap berwarna agar mudah dipahami. Outputnya Heatmap menampilkan jumlah prediksi benar dan salah antara kelas 0 dan 1 seperti yang ditunjukkan pada Gambar 14.



**Gambar 14.** Pada bagian ini ditunjukkan visualisasi confusion matrix.

### 3. Kesimpulan dan Hasil Implementasi

Dari hasil implementasi Model Naive Bayes dari praktikum ini sangat berguna untuk mendeteksi kanker payudara secara cepat berdasarkan berbagai ciri jaringan (radius, tekstur, perimeter, dan sebagainya). Implementasi ini dapat diterapkan dalam dunia nyata sebagai sistem pendukung keputusan dalam bidang kesehatan, terutama radiologi atau analisis hasil biopsi. Walaupun sederhana, model ini dapat memberikan prediksi awal yang membantu dokter membuat keputusan lanjutan.

Dari praktikum ini dapat disimpulkan bahwa algoritma Naive Bayes, khususnya GaussianNB, mampu bekerja dengan sangat baik pada dataset kanker payudara yang berisi fitur numerik. Setelah dilakukan preprocessing seperti penghapusan kolom tidak relevan, encoding diagnosis, dan standarisasi data, model dapat mencapai akurasi tinggi dan memberikan prediksi yang cukup akurat untuk membedakan kanker jinak dan ganas. Dengan proses yang mengikuti alur dalam praktikum 09, tugas mandiri ini menunjukkan bahwa Naive Bayes merupakan algoritma yang cepat, sederhana, namun sangat efektif untuk tugas klasifikasi medis.

#### **4. Link GitHub (Praktikum dan Tugas Mandiri 09)**

[https://github.com/revani18/ML\\_2025\\_Revani\\_3AI01/tree/1a1214b6b5a523feb7b6458a7f8559ac6f05e053/Praktikum09](https://github.com/revani18/ML_2025_Revani_3AI01/tree/1a1214b6b5a523feb7b6458a7f8559ac6f05e053/Praktikum09)

Praktikum:

[https://github.com/revani18/ML\\_2025\\_Revani\\_3AI01/blob/1a1214b6b5a523feb7b6458a7f8559ac6f05e053/Praktikum09/Notebooks/praktikum9.ipynb](https://github.com/revani18/ML_2025_Revani_3AI01/blob/1a1214b6b5a523feb7b6458a7f8559ac6f05e053/Praktikum09/Notebooks/praktikum9.ipynb)

Latihan:

[https://github.com/revani18/ML\\_2025\\_Revani\\_3AI01/blob/1a1214b6b5a523feb7b6458a7f8559ac6f05e053/Praktikum09/Notebooks/latihan09.ipynb](https://github.com/revani18/ML_2025_Revani_3AI01/blob/1a1214b6b5a523feb7b6458a7f8559ac6f05e053/Praktikum09/Notebooks/latihan09.ipynb)